

HHCV COURSE of Artificial Neural Networks

孟朝晖

河海大学 HHCV

Computer Vision Group of Hohai University

Contents

1 basic

Basic

Transformer 原始文献: Attention is all you need, Vaswani, arXiv:1706.03762v5

RoPE 原始文献: RoFormer : Enhanced Transformer with Rotary Position Embedding, Jianlin Su, arXiv:2104.09864v5

基本概念

Let $\mathbb{S}_N = \{w_i\}_{i=1}^N$ be a sequence of N input tokens with w_i being the i^{th} element.
 $\mathbb{S}_N$ 是 token 序列, w_i 是 token

The corresponding word embedding of $\mathbb{S}_N$ is denoted as $\mathbb{E}_N = \{\mathbf{x}_i\}_{i=1}^N$, where $\mathbf{x}_i \in \mathbb{R}^d$ is the d -dimensional word embedding vector of token w_i without position information.

$\mathbb{E}_N$ 是 token 嵌入向量序列, $\mathbf{x}_i$ 是 w_i 的 d -维词嵌入向量, 不含位置信息, 下面都称为 **token 嵌入向量** (token embedding vector)。

位置信息嵌入的一般形式

The self-attention first incorporates **position information** to the **word embeddings** and transforms them into queries, keys, and value representations.

$$\begin{cases} \mathbf{q}_m = f_q(\mathbf{x}_m, m) & m = 1, \dots, N \\ \mathbf{k}_n = f_k(\mathbf{x}_n, n) & n = 1, \dots, N \\ \mathbf{v}_n = f_v(\mathbf{x}_n, n) & n = 1, \dots, N \end{cases}$$

(1)

where $\mathbf{q}_m$, $\mathbf{k}_n$ and $\mathbf{v}_n$ incorporate the m^{th} and n^{th} positions through f_q , f_k and f_v , respectively.

解释: 这里先形式化地定义位置信息嵌入的一般公式, 即嵌入函数为 f_q , f_k and f_v , 其输入为 token 嵌入向量 $\mathbf{x}_m$, $\mathbf{x}_n$, 以及位置信息 m 和 n , 输出为融合 token 嵌入向量和位置信息的合成向量, 称为**融合向量** (token&position fusion vector)。

The query and key values are then used to compute the attention weights, while the output is computed as the weighted sum over the value representation.

$$a_{m,n} = \frac{\exp\left(\frac{\mathbf{q}_m^T \mathbf{k}_n}{\sqrt{d}}\right)}{\sum_{j=1}^N \exp\left(\frac{\mathbf{q}_m^T \mathbf{k}_j}{\sqrt{d}}\right)}$$
$$\mathbf{o}_m = \sum_{n=1}^N a_{m,n} \mathbf{v}_n$$

(2)

公式(2)补充，[这里的向量都是竖写格式](#)，先固定一个 m ($m = 1, \dots, N$)，向量 $\bar{\mathbf{a}}_m$ 表示 $\mathbf{q}_m$ 与每个 $\mathbf{k}_n$ 求内积后组成的归一化权值向量，

$$\bar{\mathbf{a}}_m = \begin{pmatrix} a_{m,1} \\ \vdots \\ a_{m,N} \end{pmatrix} \quad \sum_{j=1}^N a_{m,j} = 1 \quad m = 1, \dots, N$$

用权值向量 $\bar{\mathbf{a}}_m$ 与向量组 $\{\mathbf{v}_n\}_{n=1, \dots, N}$ 加权求和得到第 m 个输出 $\mathbf{o}_m$ ，对每个 m 如此计算，得到所有的输出 $\{\mathbf{o}_m\}_{m=1, \dots, N}$ 。

解释：这个公式就是 attention 算法，与 transformer 原文中的公式是一致的。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V = \text{softmax}_{by_row}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

The existing approaches of transformer-based position encoding mainly focus on choosing a suitable function to form Equation (1).

Absolute position embedding

绝对位置编码

A typical choice of Equation (1) is

$$\begin{cases} f_q(\mathbf{x}_i, i) := \mathbf{W}_q(\mathbf{x}_i + \mathbf{p}_i) \\ f_k(\mathbf{x}_i, i) := \mathbf{W}_k(\mathbf{x}_i + \mathbf{p}_i) \\ f_v(\mathbf{x}_i, i) := \mathbf{W}_v(\mathbf{x}_i + \mathbf{p}_i) \end{cases}$$

(3)

where $\mathbf{p}_i \in \mathbb{R}^d$ is a d-dimensional vector depending of the position of token $\mathbf{x}_i$.

用不含位置信息的 token 嵌入向量 $\mathbf{x}_i$ 叠加[位置嵌入向量](#)（position embedding vector） $\mathbf{p}_i$ 得到包含位置信息的新的融合向量 $\mathbf{q}_i$ ， $\mathbf{k}_i$ 和 $\mathbf{v}_i$ ，这样定义的位置嵌入向量 $\mathbf{p}_i$ ，其实只取决于位置 i ，所以，可以通过预定义或者预训练得到。

其中 $\mathbf{W}_q$ ， $\mathbf{W}_k$ ， $\mathbf{W}_v$ ，分别是 Q, K, V 的投影阵，即参数矩阵。

公式(3)的融合算法是[向量叠加](#)（vector addition），是 transformer 采用的方法。也可以用[向量拼接](#)（vector concatenation）或者[向量变换](#)（vector transformation）的方法。

结合公式(2)和公式(3) 对 $\mathbf{q}_m^T \mathbf{k}_n$ 进行分解

$$\mathbf{q}_m^T \mathbf{k}_n = \mathbf{x}_m^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{x}_n + \mathbf{x}_m^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{p}_n + \mathbf{p}_m^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{x}_n + \mathbf{p}_m^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{p}_n$$

(4)

解释：

$$\begin{aligned} \mathbf{q}_m &= \mathbf{W}_q(\mathbf{x}_m + \mathbf{p}_m) \\ \mathbf{k}_n &= \mathbf{W}_k(\mathbf{x}_n + \mathbf{p}_n) \end{aligned}$$

$$\mathbf{q}_m^T \mathbf{k}_n = (\mathbf{W}_q(\mathbf{x}_m + \mathbf{p}_m))^T (\mathbf{W}_k(\mathbf{x}_n + \mathbf{p}_n)) = (\mathbf{x}_m^T \mathbf{W}_q^T + \mathbf{p}_m^T \mathbf{W}_q^T)(\mathbf{W}_k \mathbf{x}_n + \mathbf{W}_k \mathbf{p}_n)$$

展开上式即得到公式(4)

进一步的解释：公式(4)中的左边 $\mathbf{q}_m^T \mathbf{k}_n$ 是合成相关度（attention），

右边第一项 $\mathbf{x}_m^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{x}_n$ 是非位置信息的嵌入向量 $\mathbf{x}_m$ 和 $\mathbf{x}_n$ 的相关度，

右边第二项 $\mathbf{x}_m^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{p}_n$ 是非位置信息的嵌入向量 $\mathbf{x}_m$ 和位置信息的嵌入向量 $\mathbf{p}_n$ 的相关度，

右边第三项 $\mathbf{p}_m^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{x}_n$ 是非位置信息的嵌入向量 $\mathbf{x}_n$ 和位置信息的嵌入向量 $\mathbf{p}_m$ 的相关度，

右边第四项 $\mathbf{p}_m^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{p}_n$ 是位置信息的嵌入向量 $\mathbf{p}_m$ 和 $\mathbf{p}_n$ 的相关度，

在以上拆解的基础上，可以对每个部分进行改进。

预定义的位置编码方法

先介绍 transformer 中的 sinusoid-encoded。

In transformer, it use sine and cosine functions of different frequencies:

$$\begin{cases} PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \\ PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \end{cases}$$

where pos is the position and i is the dimension.

直接注解：

假设有总长度为 n 的输入序列，包含 n 个向量

$$\mathbf{z} = (z^{(0)}, \dots, z^{(n-1)})$$

每个（第 pos 个，总数 n 个）向量 $z^{(pos)}$ 的维度为 d_{model}

$$z^{(pos)} = (z_0^{(pos)}, \dots, z_{d_{model}-1}^{(pos)}) \quad pos = 0, \dots, (n-1)$$

则其对应的（第 pos 个，总数 n 个）嵌入位置编码向量为 $pe^{(pos)}$ (positional encoding)，其维度同样为 d_{model}

$$pe^{(pos)} = (pe_0^{(pos)}, \dots, pe_{d_{model}-1}^{(pos)}) \quad pos = 0, \dots, (n-1)$$

其计算公式为

$$\begin{cases} pe_{2i}^{(pos)} = PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) & i = 0, \dots, \left(\frac{d_{model}}{2} - 1\right) \\ pe_{2i+1}^{(pos)} = PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) & i = 0, \dots, \left(\frac{d_{model}}{2} - 1\right) \end{cases}$$

进一步注解：

以 $d_{model} = 512$ 为例，位置编码向量 $pe^{(pos)}$ 的分量为交替计算 $\sin(\omega_i \cdot pos)$ 和 $\cos(\omega_i \cdot pos)$,

$$pe^{(pos)} = \begin{bmatrix} \sin(\omega_0 \cdot pos) \\ \cos(\omega_0 \cdot pos) \\ \vdots \\ \vdots \\ \sin(\omega_{255} \cdot pos) \\ \cos(\omega_{255} \cdot pos) \end{bmatrix}_{512 \times 1}$$

其中的频率因子 ω_i 为

$$\omega_i = \frac{1}{10000^{\frac{2i}{d_{model}}}} \quad i = 0, \dots, \left(\frac{d_{model}}{2} - 1\right)$$

$$\omega_i = \frac{1}{10000^{\frac{2i}{512}}} \quad i = 0, \dots, 255$$

观察一下频率因子的变化范围，当频率下标线性(0,64,128,192,255)增加时，频率值指数级递减 ($10^0, 10^{-1}, 10^{-2}, 10^{-3}, 10^{-4}$),

$$\omega_0 = \frac{1}{10000^{\frac{2 \times 0}{512}}} = 1$$

$$\omega_{64} = \frac{1}{10000^{\frac{2 \times 64}{512}}} = \frac{1}{10}$$

$$\omega_{128} = \frac{1}{10000^{\frac{2 \times 128}{512}}} = \frac{1}{100}$$

$$\omega_{192} = \frac{1}{10000^{\frac{2 \times 192}{512}}} = \frac{1}{1000}$$

$$\omega_{255} = \frac{1}{10000^{\frac{2 \times 255}{512}}} \approx \frac{1}{10000}$$

例如

$$pe^{(pos)} = \begin{bmatrix} \sin(\omega_0 \cdot pos) \\ \cos(\omega_0 \cdot pos) \\ \vdots \\ \sin(\omega_{64} \cdot pos) \\ \cos(\omega_{64} \cdot pos) \\ \vdots \\ \sin(\omega_{128} \cdot pos) \\ \cos(\omega_{128} \cdot pos) \\ \vdots \\ \sin(\omega_{192} \cdot pos) \\ \cos(\omega_{192} \cdot pos) \\ \vdots \\ \sin(\omega_{255} \cdot pos) \\ \cos(\omega_{255} \cdot pos) \end{bmatrix}_{512 \times 1} = \begin{bmatrix} \sin(10^0 \cdot pos) \\ \cos(10^0 \cdot pos) \\ \vdots \\ \sin(10^{-1} \cdot pos) \\ \cos(10^{-1} \cdot pos) \\ \vdots \\ \sin(10^{-2} \cdot pos) \\ \cos(10^{-2} \cdot pos) \\ \vdots \\ \sin(10^{-3} \cdot pos) \\ \cos(10^{-3} \cdot pos) \\ \vdots \\ \sin(10^{-4} \cdot pos) \\ \cos(10^{-4} \cdot pos) \end{bmatrix}_{512 \times 1}$$

一个位置编码向量的特性：

频率 ω_i 对 $\sin(\omega_i \cdot pos)$ 或 $\cos(\omega_i \cdot pos)$ 的值的影响是，频率越大， $\sin$ 或 $\cos$ 的值变化越快，频率越小， $\sin$ 或 $\cos$ 的值变化越慢，对于某个特定的位置 pos ，其位置编码向量 $pe^{(pos)}$ 的 512 个分量值，逐渐从快速变化到慢速变化， $\sin$ 和 $\cos$ 的交替取值，使得相邻位置的分量值保持一定的相位差，直观上形成**条纹状分布**。

RoPE position embedding

RoPE 位置编码

各符号假设与前述一致，

$$\begin{aligned} f_q(\mathbf{x}_m, m) &= \mathbf{R}_{\theta, m}^d (\mathbf{W}_q \mathbf{x}_m) \\ f_k(\mathbf{x}_n, n) &= \mathbf{R}_{\theta, n}^d (\mathbf{W}_k \mathbf{x}_n) \\ \mathbf{q}_m^T \mathbf{k}_n &= (\mathbf{R}_{\theta, m}^d \mathbf{W}_q \mathbf{x}_m)^T (\mathbf{R}_{\theta, n}^d \mathbf{W}_k \mathbf{x}_n) = (\mathbf{W}_q \mathbf{x}_m)^T \mathbf{R}_{\theta, n-m}^d (\mathbf{W}_k \mathbf{x}_n) \end{aligned}$$

(5)

其中的 $\mathbf{R}_{\theta, m}^d$ 为

$$\mathbf{R}_{\theta, m}^d = \begin{pmatrix} \cos m\theta_1 & -\sin m\theta_1 & 0 & 0 & \cdots & \cdots & 0 & 0 \\ \sin m\theta_1 & \cos m\theta_1 & 0 & 0 & \cdots & \cdots & 0 & 0 \\ 0 & 0 & \cos m\theta_2 & -\sin m\theta_2 & \cdots & \cdots & 0 & 0 \\ 0 & 0 & \sin m\theta_2 & \cos m\theta_2 & \cdots & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots & & & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cdots & \cos m\theta_{d/2} & -\sin m\theta_{d/2} \\ 0 & 0 & 0 & 0 & \cdots & \cdots & \sin m\theta_{d/2} & \cos m\theta_{d/2} \end{pmatrix}$$

解释：公式(5)的前两个公式表明，位置信息嵌入是独立进行的，即**绝对位置信息嵌入**，

公式 $f_q(\mathbf{x}_m, m) = \mathbf{R}_{\theta, m}^d (\mathbf{W}_q \mathbf{x}_m)$ 表示位置 m 的信息嵌入 $\mathbf{x}_m$ 时，与其他位置 n 无关，公式 $f_k(\mathbf{x}_n, n) = \mathbf{R}_{\theta, n}^d (\mathbf{W}_k \mathbf{x}_n)$ 表示位置 n 的信息嵌入 $\mathbf{x}_n$ 时，也与其他位置 m 无关，而且这种嵌入可以**拆分**为与位置信息无关的投影 $(\mathbf{W}_q \mathbf{x}_m)$ 、 $(\mathbf{W}_k \mathbf{x}_n)$ 以及单纯的**绝对位置信息嵌入**算子（旋转矩阵） $\mathbf{R}_{\theta, m}^d$ 、 $\mathbf{R}_{\theta, n}^d$ ，旋转矩阵只包含绝对位置信息 m 或 n ，以及旋转参数组 θ ，

公式(16-1)的第三个公式表明，嵌入位置信息后，求相关度（attention）的表达式 $q_m^T k_n$ 可以**拆分**为两个与位置信息无关的投影 $(W_q x_m)^T$ 和 $(W_k x_n)$ ，以及单纯的**相对位置信息嵌入**算子（旋转矩阵） $R_{\Theta, n-m}^d$ ，这个旋转矩阵只包含相对位置信息 $(n-m)$ ，以及旋转参数组 Θ ，

解释：**运算模块拆分**表示的意义在于，从反向传播学习算法的角度，一个运算模块，能够按照信息来源进行拆分，则**反向学习的路径**就会很清晰，对模型设计和改进都很重要。

这里位置编码方案与 transformer 是一致的，即先计算维度为 $(\frac{d}{2})$ 的位置嵌入向量 $pe^{(m)}$ ， m 为位置信息，

$$pe^{(m)} = [pe_i^m]_{(\frac{d}{2}) \times 1} = \begin{bmatrix} \sin(m\theta_1) \\ \cos(m\theta_1) \\ \vdots \\ \sin(m\theta_{d/2}) \\ \cos(m\theta_{d/2}) \end{bmatrix}_{(\frac{d}{2}) \times 1}$$

θ_i 的设计也与 transformer 一致

$$\Theta = \left\{ \theta_i = 10000^{-\frac{2(i-1)}{d}}, \quad i \in \left[1, 2, \dots, \frac{d}{2} \right] \right\}$$

区别在于，transformer 用向量叠加，RoPE 用向量变换，具体为旋转变换。


序列位置编码为向量

先看一个**钟表**的例子，假设将半天时间内的所有时刻按秒顺序排列，则可以对应如下：

00:00:00	0
01:00:00	3600
02:00:00	7200
$\vdots$	$\vdots$
$\vdots$	$\vdots$
12:00:00	43200

左边是日常使用的时、分、秒，右边是纯秒数，是一维序列，秒数就是其序列位置（位置信息）。日常使用的时、分、秒，实际上可以看做是一个 3 维向量，向量的每个分量的取值范围有差别，时（0~11）、分（0~59）、秒（0~59），相当于分别是 12 进制，60 进制，60 进制。

从编码算法的角度来看，相当于将**一维序列的位置信息**（秒数），**编码**（位置嵌入编码）为一个 **3 维向量**。




编码的算法为，设置三个**转速不同的圆环**，时环，分环和秒环，用三个圆环上**圆周运动位置**，编码一个**一维序列的位置信息**，时环的指针**慢速旋转**，秒数（一维位置）每 3600 秒进一格，分环的指针**中速旋转**，秒数（一维位置）每 60 秒进一格，秒环的指针**快速旋转**，秒数（一维位置）每 1 秒进一格。

时、分、秒 3 维向量的每个分量的取值为标量值（一个整数值），实际上是在圆周上进行线性离散定位（一维刻度值定位）。

注意一个要点，钟表的“时-分-秒”3 维编码方案是没有冗余的，即半天时间内的所有时刻“秒数”与“时-分-秒”是一一对应的，即钟表的“时-分-秒”3 维编码方案只能表达 12 小时内的时刻和变化。

transformer 的 256 个圆环

回到 transformer 的编码方案，从编码算法的角度来看，相当于将**一维序列的位置信息**（自然数 n ），**编码**（位置嵌入编码）为一个 **512 维向量**。



设置 256 个**转速不同的圆环**（circle oscillator），频率 ω_i 为第 i 个圆环 $circle_i$ 的转速，转速取值从 1 到 $\frac{1}{10000}$ ($\omega_i = \frac{1}{10000 \cdot 2^i}$)，**一维序列的位置信息**的值为 pos （自然数 pos ），则 $\theta_i = (\omega_i \cdot pos)$ 表示在第 i 个圆环上的**旋转量**，注意， $\theta_i = (\omega_i \cdot pos)$ 是角度（弧度值），先总结**两个要点**：

（1）每个圆环的表达力，只局限于圆周上的点的位置（取值范围 $[0 \sim 2\pi)$ ），如果第 i 个圆环的旋转量（弧度值） $\theta_i = (\omega_i \cdot pos)$ 超出了 $[0 \sim 2\pi)$ 的范围，则当前圆环 i 并不能记忆旋转量（弧度值） θ_i 在自己的圆环上转过了几圈，而只能在 $[0 \sim 2\pi)$ 范围内定位取值，相当于角度值 θ_i 对 2π 取模的余数，

（2）不同于钟表的例子，这里圆周上的当前点的位置用**二维坐标表示** (x_i, y_i) ，即在每个圆环上的编码需要两个值， $y_i = \sin(\omega_i \cdot pos)$ 和 $x_i = \cos(\omega_i \cdot pos)$ ，分别表示当前点的纵坐标与横坐标，所以圆环的总数是 256，而位置嵌入编码向量的维度是 512 维。

尺度化的 oscillator 特征算子

（multi-scale oscillator feature extractor）

上述圆环可以称为**旋转圆环**（rotate ring），是一个既有状态，又有运动的标准**振荡子**（oscillator）模型，**状态**就是圆周上的点的位置，**运动**就是圆周上的点做转圈运动，运动**参数**即为转速 ω_i 。这样

一个震荡子，可以认为是一个**特征提取器**（feature extractor），而特征提取的**尺度**取决于转速 ω_i 。

转速 ω_i 对 $\sin(\omega_i \cdot pos)$ 或 $\cos(\omega_i \cdot pos)$ 的值的影响是：

转速越大， $\sin$ 或 $\cos$ 的值变化越快，相对小的 pos 变化也会有比较显著的编码值的变化，适合提取**小尺度**的信息和变化。

转速越小， $\sin$ 或 $\cos$ 的值变化越慢，相对大的 pos 变化才会有比较显著的编码值的变化，适合提取**大尺度**的信息和变化。

特征提取既是**静态**的（**绝对**的，static/absolute），也是**动态**的（**相对**的，dynamic/relative）。静态是指上述针对一个单一位置信息构造编码的方法。

动态性或相对性，举例如下。

举个具体的例子，假设有两个位置信息， $pos_1 = 100$ ， $pos_2 = 414 \approx 100 + 100\pi$ 。所谓两个位置，既可以是两个 tokens 对应的两个位置（**相对性**），也可以是同一个 token 在不同时刻（或不同场景下）的位置变化（**动态性**）。

又假设有某个圆环 $circle_i$ 其转速为 $\omega_i = \frac{1}{100}$ ，则对应圆环 $circle_i$ 的编码值为：

$$circle_i : \omega_i = \frac{1}{100} \quad \begin{cases} pos_1 = 100 \\ pos_2 = 414 \end{cases}$$

$$\begin{cases} y_i = \sin(\omega_i \cdot pos) \\ x_i = \cos(\omega_i \cdot pos) \end{cases}$$

$$\begin{cases} y_1 = \sin(\omega_i \cdot pos_1) = \sin\left(\frac{1}{100} \cdot 100\right) = \sin(1) \\ x_1 = \cos(\omega_i \cdot pos_1) = \cos\left(\frac{1}{100} \cdot 100\right) = \cos(1) \end{cases}$$

$$\begin{cases} y_2 = \sin(\omega_i \cdot pos_2) = \sin\left(\frac{1}{100} \cdot 414\right) \approx \sin(1 + \pi) \\ x_2 = \cos(\omega_i \cdot pos_2) = \cos\left(\frac{1}{100} \cdot 414\right) \approx \cos(1 + \pi) \end{cases}$$

那么，两个位置 pos_1 和 pos_2 在对应圆环 $circle_i$ 上的编码值 (y_1, x_1) 和 (y_2, x_2) 的相位差达到了几乎最大（相位差为 π ，编码值正负翻转），说明，两个位置 pos_1 和 pos_2 的**相对位置信息差**在圆环 $circle_i$ 这个**特征提取器**上获得显著表征。